


실습하며 배우는
딥러닝 입문
with **Kaggle**



타이타닉 생존자 예측부터 자율주행 자동차까지

[보조자료] 제공(www.booker.co.kr)

장원두 지음

· 파이썬 소스 코드



실습하며 배우는

딥러닝 입문 WITH KAGGLE

4장: 구글 코랩과
데이터 분석의
기초



목 차

- 4.1 리눅스 시스템 기초
 - 4.2 구글 코랩과 캐글의 연동
 - 4.3 구글 코랩과 타이타닉 데이터
 - 4.4 파이썬 코드로 타이타닉 데이터 분석하기
 - 4.5 데이터 분석 실습: 코로나19 확진자 추이 데이터
- 




배경


- 구글 코랩은 리눅스 시스템 위에서 동작
- 리눅스 시스템에 대한 기초적인 이해 필요

운영체제

- 컴퓨터 상에서 동작하는 '운영체제' (윈도우10 등과 유사)
- 컴퓨터는 하드웨어와 소프트웨어로 구성
- 소프트웨어는 윈도우, 리눅스 등의 운영체제 위에서 동작



하드웨어



소프트웨어



리눅스

- 기본 소스가 공개되어 있어 다양한 수정과 배포가 이루어지고 있음
- 레드햇 리눅스, 페도라, 센트 오에스, 우분투, 페퍼민트 등 다양한 종류의 리눅스가 있음
- 코랩에서는 우분투를 사용 (구글 운영정책 등에 따라 바뀔 수 있음!)

사용중인 운영체제 확인 코드



```
!cat /etc/issue.net
```




Linux





코랩

- 코랩 센터에 있는 서버와 연결하여 해당 컴퓨터의 자원을 사용
- 코드의 작성은 로컬 (local) 컴퓨터에서 이루어지지만,
- 실행 버튼을 누르는 순간 코드가 서버로 전송되어 실행됨
- 실행 후 결과는 다시 로컬 컴퓨터로 전송되어 브라우저 화면에 표시됨





코랩의 폴더 구조

- 좌측 상단의 메뉴를 클릭하여 폴더 구조의 확인 가능. 윈도우 탐색기의 폴더 구조와 유사
- .. 아이콘을 눌러 상위 폴더로 이동 가능
- 처음 연결하면 현재 폴더가 /content 에 위치
- 폴더 이름에서 마우스 우측 버튼을 클릭하면, 파일 업로드, 이름 바꾸기, 삭제 등의 다양한 기능을 동작시키는 메뉴가 등장

업로드

새 파일


새 폴더

폴더 이름 바꾸기

폴더 삭제

경로 복사

새로고침





리눅스 명령

- 폴더 생성 등의 명령은, 코랩 코드 창에서 리눅스 명령으로도 실행 가능
- 명령 앞에 느낌표를 붙여 실행 (느낌표 없이도 실행되는 경우도 있음)

〈표 4-1〉 리눅스 명령 리스트

명령	설명	예시	예시 설명
pwd	현재 작업 폴더 확인	pwd	현재 폴더를 확인한다.
ls	파일 리스트 보기	ls	현재 작업 폴더의 파일 리스트를 보여준다.
cd	작업 폴더 위치 변경	cd content	content 폴더로 이동한다(작업 폴더 변경).
!mv	파일 이동	!mv a.json ~/.kaggle/	a.json 파일을 ~/.kaggle/ 폴더로 이동시킨다.
!chmod	권한 변경	!chmod 600 filename.json	filename.json의 권한을 600으로 설정한다. 600은 읽기/쓰기를 사용자 자신만 할 수 있도록 하는 것이다.
!unzip	압축 풀기	!unzip 파일 이름.zip	zip으로 압축된 파일의 압축을 해제한다.



리눅스 명령

- 현재 작업 폴더 확인

```

▶ pwd
↳ /content
    
```

- 파일 리스트 보기

```

▶ ls
↳ sample_data/
    
```

〈표 4-1〉 리눅스 명령 리스트

명령	설명	예시	예시 설명
pwd	현재 작업 폴더 확인	pwd	현재 폴더를 확인한다.
ls	파일 리스트 보기	ls	현재 작업 폴더의 파일 리스트를 보여준다.
cd	작업 폴더 위치 변경	cd content	content 폴더로 이동한다(작업 폴더 변경).
!mv	파일 이동	!mv a.json ~/.kaggle/	a.json 파일을 ~/.kaggle/ 폴더로 이동시킨다.
!chmod	권한 변경	!chmod 600 filename.json	filename.json의 권한을 600으로 설정한다. 600은 읽기/쓰기를 사용자 자신만 할 수 있도록 하는 것이다.
!unzip	압축 풀기	!unzip 파일 이름.zip	zip으로 압축된 파일의 압축을 해제한다.



리눅스 명령

- 작업 폴더 위치 변경



```
cd sample_data
```



```
/content/sample_data
```

- 파일 리스트 보기



```
ls
```



```
anscombe.json* mnist_test.csv  
california_housing_test.csv  
mnist_train_small.csv  
california_housing_train.csv README.md*
```

〈표 4-1〉 리눅스 명령 리스트

명령	설명	예시	예시 설명
pwd	현재 작업 폴더 확인	pwd	현재 폴더를 확인한다.
ls	파일 리스트 보기	ls	현재 작업 폴더의 파일 리스트를 보여준다.
cd	작업 폴더 위치 변경	cd content	content 폴더로 이동한다(작업 폴더 변경).
!mv	파일 이동	!mv a.json ~/.kaggle/	a.json 파일을 ~/.kaggle/ 폴더로 이동시킨다.
!chmod	권한 변경	!chmod 600 filename.json	filename.json의 권한을 600으로 설정한다. 600은 읽기/쓰기를 사용자 자신만 할 수 있도록 하는 것이다.
!unzip	압축 풀기	!unzip 파일 이름.zip	zip으로 압축된 파일의 압축을 해제한다.



리눅스 명령

- 작업 폴더 위치 변경 (상위폴더로 이동)

```
▶ cd ..
↳ /content/
```

- 파일 리스트 확인

```
▶ ls
↳ sample_data/
```

〈표 4-1〉 리눅스 명령 리스트

명령	설명	예시	예시 설명
pwd	현재 작업 폴더 확인	pwd	현재 폴더를 확인한다.
ls	파일 리스트 보기	ls	현재 작업 폴더의 파일 리스트를 보여준다.
cd	작업 폴더 위치 변경	cd content	content 폴더로 이동한다(작업 폴더 변경).
!mv	파일 이동	!mv a.json ~/.kaggle/	a.json 파일을 ~/.kaggle/ 폴더로 이동시킨다.
!chmod	권한 변경	!chmod 600 filename.json	filename.json의 권한을 600으로 설정한다. 600은 읽기/쓰기를 사용자 자신만 할 수 있도록 하는 것이다.
!unzip	압축 풀기	!unzip 파일 이름.zip	zip으로 압축된 파일의 압축을 해제한다.



리눅스 명령

- ls의 -al 옵션
- 파일의 다양한 정보(크기, 생성일자 등)를 함께 표시



ls -al



```
total 55512
drwxr-xr-x 1 root root 4096 Jul 16 13:20 ./
drwxr-xr-x 1 root root 4096 Jul 16 13:20 ../
-rwxr-xr-x 1 root root 1697 Jan 1 2000  anscombe.json*
-rw-r--r-- 1 root root 301141 Jul 16 13:20 california_housing_test.csv
-rw-r--r-- 1 root root 1706430 Jul 16 13:20 california_housing_train.csv
-rw-r--r-- 1 root root 18289443 Jul 16 13:20 mnist_test.csv
-rw-r--r-- 1 root root 36523880 Jul 16 13:20 mnist_train_small.csv
-rwxr-xr-x 1 root root 930 Jan 1 2000  README.md*
```

- mkdir, mv, chmod, unzip 명령의 실습은 차후에 진행

〈표 4-1〉 리눅스 명령 리스트

명령	설명	예시	예시 설명
pwd	현재 작업 폴더 확인	pwd	현재 폴더를 확인한다.
ls	파일 리스트 보기	ls	현재 작업 폴더의 파일 리스트를 보여준다.
cd	작업 폴더 위치 변경	cd content	content 폴더로 이동한다(작업 폴더 변경).
!mv	파일 이동	!mv a.json ~/.kaggle/	a.json 파일을 ~/.kaggle/ 폴더로 이동시킨다.
!chmod	권한 변경	!chmod 600 filename.json	filename.json의 권한을 600으로 설정한다. 600은 읽기/쓰기를 사용자 자신만 할 수 있도록 하는 것이다.
!unzip	압축 풀기	!unzip 파일 이름.zip	zip으로 압축된 파일의 압축을 해제한다.



파일정보와 권한

- 파일정보

```
total 55512
drwxr-xr-x 1 root root 4096 Jul 16 13:20 ./
drwxr-xr-x 1 root root 4096 Jul 16 13:20 ../
-rwxr-xr-x 1 root root 1697 Jan 1 2000  anscombe.json*
-rw-r--r-- 1 root root 301141 Jul 16 13:20 california_housing_test.csv
-rw-r--r-- 1 root root 1706430 Jul 16 13:20 california_housing_train.csv
-rw-r--r-- 1 root root 18289443 Jul 16 13:20 mnist_test.csv
-rw-r--r-- 1 root root 36523880 Jul 16 13:20 mnist_train_small.csv
-rwxr-xr-x 1 root root 930 Jan 1 2000  README.md*
```

Diagram showing ownership and group assignment for the first two files in the listing:

- 소유자 (Owner):** Indicated by a blue box around 'root' in the first two columns of the first two lines.
- 그룹 (Group):** Indicated by a red box around 'root' in the third column of the first two lines.

- 윈도우 10은 개인용으로 활용되는 운영체제로, 쉽게 다른 사용자의 파일에 접근 가능
- 리눅스는 여러 사용자가 동시에 사용할 수 있는 운영체제로, 보안이 중요함
- 파일별로 소유자와 그룹이 지정됨
- 소유자
 - 해당 파일을 소유하고 있는 사용자명
- 그룹
 - 해당 파일에 접근가능한 사용자들의 그룹

<표 4-1> 리눅스 명령 리스트

명령	설명	예시	예시 설명
pwd	현재 작업 폴더 확인	pwd	현재 폴더를 확인한다.
ls	파일 리스트 보기	ls	현재 작업 폴더의 파일 리스트를 보여준다.
cd	작업 폴더 위치 변경	cd content	content 폴더로 이동한다(작업 폴더 변경).
!mv	파일 이동	!mv a.json ~/.kaggle/	a.json 파일을 ~/.kaggle/ 폴더로 이동시킨다.
!chmod	권한 변경	!chmod 600 filename.json	filename.json의 권한을 600으로 설정한다. 600은 읽기/쓰기를 사용자 자신만 할 수 있도록 하는 것이다.
!unzip	압축 풀기	!unzip 파일 이름.zip	zip으로 압축된 파일의 압축을 해제한다.



파일정보와 권한

- 파일정보

total 55512

```
drwxr-xr-x 1 root root 4096 Jul 16 13:20 ./
drwxr-xr-x 1 root root 4096 Jul 16 13:20 ../
-rwxr-xr-x 1 root root 1697 Jan 1 2000  anscombe.json*
-rw-r--r-- 1 root root 301141      Jul 16 13:20  california_housing_test.csv
-rw-r--r-- 1 root root 1706430 Jul 16 13:20  california_housing_train.csv
-rw-r--r-- 1 root root 18289443 Jul 16 13:20  mnist_test.csv
-rw-r--r-- 1 root root 36523880 Jul 16 13:20  mnist_train_small.csv
-rwxr-xr-x 1 root root 930   Jan 1 2000  README.md*
```

- 가장 앞의 d는 디렉터리임을 나타냄. - 는 파일
- 9개 영어는 3개씩 묶여서, 각각 소유자/그룹/기타사용자의 권한을 나타냄
- r은 읽기 권한, w는 쓰기 권한, x는 접근 권한, -는 해당 권한이 없음
- 이진수를 활용하여 이를 숫자로 표시할 수 있음. 600은 사용자 자신만 읽기 쓰기를 할 수 있는 권한임

소유자			그룹			기타사용자		
R	W	X	R	W	X	R	W	X
r	w	x	r	-	x	r	-	x
1	1	1	1	0	1	1	0	1
7			5			5		

〈표 4-1〉 리눅스 명령 리스트

명령	설명	예시	예시 설명
pwd	현재 작업 폴더 확인	pwd	현재 폴더를 확인한다.
ls	파일 리스트 보기	ls	현재 작업 폴더의 파일 리스트를 보여준다.
cd	작업 폴더 위치 변경	cd content	content 폴더로 이동한다(작업 폴더 변경).
!mv	파일 이동	!mv a.json ~/.kaggle/	a.json 파일을 ~/.kaggle/ 폴더로 이동시킨다.
!chmod	권한 변경	!chmod 600 filename.json	filename.json의 권한을 600으로 설정한다. 600은 읽기/쓰기를 사용자 자신만 할 수 있도록 하는 것이다.
!unzip	압축 풀기	!unzip 파일 이름.zip	zip으로 압축된 파일의 압축을 해제한다.




목 차

- 4.1 리눅스 시스템 기초
 - 4.2 구글 코랩과 캐글의 연동
 - 4.3 구글 코랩과 타이타닉 데이터
 - 4.4 파이썬 코드로 타이타닉 데이터 분석하기
 - 4.5 데이터 분석 실습: 코로나19 확진자 추이 데이터
- 




실습순서

1. 계정정보 화면에서 API 토큰 다운로드 (캐글 데이터셋 등에 접근하기 위한 용도)



[그림 4-2] 계정 정보로 들어가는 메뉴



[그림 4-3] API 토큰 생성 버튼과 다운로드 위치 지정 화면



실습순서

1. 계정정보 화면에서 API 토큰 다운로드 (캐글 데이터셋 등에 접근하기 위한 용도)
2. 캐글 설치



```
!pip install kaggle
```



실습순서

1. 계정정보 화면에서 API 토큰 다운로드 (캐글 데이터셋 등에 접근하기 위한 용도)
2. 캐글 설치
3. 코랩 폴더에 API 토큰 업로드

- 폴더에 API 토큰 업로드



```
from google.colab import files  
files.upload()
```

- 업로드된 파일 확인



```
ls
```



```
from google.colab import files  
files.upload()
```



파일 선택 선택된 파일 없음

Cancel upload



|





실습순서

1. 계정정보 화면에서 API 토큰 다운로드 (캐글 데이터셋 등에 접근하기 위한 용도)
2. 캐글 설치
3. 코랩 폴더에 API 토큰 업로드
4. 업로드된 토큰을 ~/.kaggle폴더로 이동

폴더 생성

- mkdir [생성할 폴더 경로]
- ~ 는 사용자의 기본 폴더를 의미. 코랩에서는 /root 폴더

파일 이동

- mv [기존 파일 경로] [옮길 파일 경로]
- 옮길 파일 경로에서 파일 이름을 생략하고 폴더 위치만 지정 가능
- 여기에서는 kaggle.json 파일을 /root/.kaggle 폴더로 옮기라는 의미

- 폴더 생성



```
!mkdir ~/.kaggle
```

- 생성된 폴더로 파일 이동



```
!mv kaggle.json ~/.kaggle/
```

- 이동된 파일 확인



```
cd ~/.kaggle/  
pwd  
ls -al
```



실습순서

1. 계정정보 화면에서 API 토큰 다운로드 (캐글 데이터셋 등에 접근하기 위한 용도)
2. 캐글 설치
3. 코랩 폴더에 API 토큰 업로드
4. 업로드된 토큰을 ~/.kaggle폴더로 이동
5. 이동된 토큰의 권한을 변경



```
!chmod 600 ~/.kaggle/*
```

권한 변경

- chmod [권한] [파일경로]
- 특정 파일의 권한을 지정
- 파일경로에서 * 는 해당 폴더의 모든 파일을 지정하는 것
- 기타사용자의 권한이 크면 보안상 좋지 않음
- 600은 소유자의 읽기와 쓰기만 가능하도록 하는 설정임

소유자			그룹			기타사용자		
R	W	X	R	W	X	R	W	X
r	w	-	-	-	-	-	-	-
1	1	0	0	0	0	0	0	0
6			0			0		



실습순서

1. 계정정보 화면에서 API 토큰 다운로드 (캐글 데이터셋 등에 접근하기 위한 용도)
2. 캐글 설치
3. 코랩 폴더에 API 토큰 업로드
4. 업로드된 토큰을 ~/.kaggle폴더로 이동
5. 이동된 토큰의 권한을 변경
6. 캐글 대회 리스트 확인



!kaggle competitions list

!kaggle competitions list

Warning: Looks like you're using an outdated API Version, please consider updating (server 1.5.12 / client 1.5.4)

ref	deadline	category	reward	teamCount	userHasEntered
contradictory-my-dear-watson	2030-07-01 23:59:00	Getting Started	Prizes	239	False
gan-getting-started	2030-07-01 23:59:00	Getting Started	Prizes	406	False
tpu-getting-started	2030-06-03 23:59:00	Getting Started	Knowledge	1057	False
digit-recognizer	2030-01-01 00:00:00	Getting Started	Knowledge	6918	False
titanic	2030-01-01 00:00:00	Getting Started	Knowledge	76170	True
house-prices-advanced-regression-techniques	2030-01-01 00:00:00	Getting Started	Knowledge	15667	True
connectx	2030-01-01 00:00:00	Getting Started	Knowledge	1111	False
nlp-getting-started	2030-01-01 00:00:00	Getting Started	Knowledge	3778	False
competitive-data-science-predict-future-sales	2022-12-31 23:59:00	Playground	Kudos	12255	False
rsna-miccai-brain-tumor-radiogenomic-classification	2021-10-15 23:59:00	Featured	\$30,000	339	False
learnplatform-covid19-impact-on-digital-learning	2021-09-30 23:59:00	Analytics	\$20,000	0	False
g2net-gravitational-wave-detection	2021-09-29 23:59:00	Research	\$15,000	442	False
optiver-realized-volatility-prediction	2021-09-27 23:59:00	Featured	\$100,000	1566	False
mlb-player-digital-engagement-forecasting	2021-09-15 23:59:00	Featured	\$50,000	852	False
tabular-playground-series-aug-2021	2021-08-31 23:59:00	Playground	Swag	345	False
jane-street-market-prediction	2021-08-23 23:59:00	Featured	\$100,000	4245	False
seti-breakthrough-listen	2021-08-18 23:59:00	Research	\$15,000	471	False
hungry-geese	2021-08-09 23:59:00	Playground	Prizes	879	False
siim-covid19-detection	2021-08-09 23:59:00	Featured	\$100,000	1191	False
google-smartphone-decimeter-challenge	2021-08-04 23:59:00	Research	\$10,000	802	False

- root/.kaggle 폴더에 업로드된 토큰을 통해 kaggle 계정에 직접 접근 가능해짐
- !kaggle 명령을 통해 kaggle의 여러 기능을 사용 가능



목 차


- 4.1 리눅스 시스템 기초
 - 4.2 구글 코랩과 캐글의 연동
 - 4.3 구글 코랩과 타이타닉 데이터
 - 4.4 파이썬 코드로 타이타닉 데이터 분석하기
 - 4.5 데이터 분석 실습: 코로나19 확진자 추이 데이터
- 



실습순서

1. 구글 드라이브의 Colab Notebook 폴더에, titanic_data라는 이름의 폴더 생성

- 코랩에 저장된 데이터는 해당 서버와의 연결이 종료되면 삭제될 수 있음
- 구글 드라이브와 코랩을 연동하여 데이터를 장기간 저장하여 보관 가능
- 구글 드라이브(drive.google.com)에 접속하고 Colab Notebook 폴더로 이동
- 마우스 우측 버튼을 클릭하여 titanic_data 폴더 생성



[그림 4-4] 폴더 생성 메뉴와 폴더 이름 입력 화면



실습순서

1. 구글 드라이브의 Colab Notebook 폴더에, titanic_data라는 이름의 폴더 생성
2. 코랩에서 구글 드라이브 연결

- 외부 디렉터리를 작업중인 컴퓨터에 연결하여 사용하는 작업을 마운트(mount)라고 함
- 구글 드라이브와의 연결을 위해 링크를 클릭하여 구글 계정으로 로그인하고, 인증 코드를 복사해서 코랩 창에 붙여 넣어야 함

- 코랩에서 현재 폴더 확인.
content 폴더가 아닌 경우 해당 위치로 이동



```
pwd
```

- content 폴더 안에 gdrive 폴더 생성. ls 명령으로 생성된 폴더 확인



```
mkdir gdrive
```



```
ls
```

- 구글 드라이브를 gdrive 폴더와 연결



```
from google.colab import drive  
drive.mount('/content/gdrive')
```



Go to this URL in a browser: https://accounts.google.com/o/oauth2/auth?client_id=...




Enter your authorization code:



실습순서

1. 구글 드라이브의 Colab Notebook 폴더에, titanic_data라는 이름의 폴더 생성
2. 코랩에서 구글 드라이브 연결
3. 코랩의 폴더 메뉴에서 구글 드라이브 확인

- 구글 드라이브와 연결이 완료되면, 구글 드라이브의 폴더/파일을 코랩에서 바로 살펴볼 수 있음
- 코랩의 폴더 메뉴에서 구글 드라이브의 내용 확인




[그림 4-5] 연동이 완료된 폴더 구조



실습순서

1. 구글 드라이브의 Colab Notebook 폴더에, titanic_data라는 이름의 폴더 생성
2. 코랩에서 구글 드라이브 연결
3. 코랩의 폴더 메뉴에서 구글 드라이브 확인
4. 타이타닉 데이터 다운로드



- 타이타닉 데이터를 저장할 위치로 이동



```
cd '/content/gdrive/My Drive/Colab Notebooks/titanic_data'
```

- 타이타닉 데이터 다운로드
- 다운로드에 필요한 명령은 캐글의 타이타닉 데이터 페이지에



있음

```
!kaggle competitions download -c titanic
```



실습순서

1. 구글 드라이브의 Colab Notebook 폴더에, titanic_data라는 이름의 폴더 생성
2. 코랩에서 구글 드라이브 연결
3. 코랩의 폴더 메뉴에서 구글 드라이브 확인
4. 타이타닉 데이터 다운로드
5. 파일 이름 더블클릭하여 내용 확인

- 코랩 상에서 데이터를 바로 확인해 볼 수 있음

train.csv X

1 to 10 of 891 entries Filter

PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	F
1	0	3	Braund, Mr. Owen Harris	male	22	1	0	A/5 21171	7.2
2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Thayer)	female	38	1	0	PC 17599	71.
3	1	3	Heikkinen, Miss. Laina	female	26	0	0	STON/O2. 3101282	7.9
4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35	1	0	113803	53.
5	0	3	Allen, Mr. William Henry	male	35	0	0	373450	8.0
6	0	3	Moran, Mr. James	male		0	0	330877	8.4
7	0	1	McCarthy, Mr. Timothy J	male	54	0	0	17463	51.
8	0	3	Palsson, Master. Gosta Leonard	male	2	3	1	349909	21.
9	1	3	Johnson, Mrs. Oscar W (Elisabeth Vilhelmina Berg)	female	27	0	2	347742	11.
10	1	2	Nasser, Mrs. Nicholas (Adele Achem)	female	14	1	0	237736	30.

Show 10 per page

1 2 10 80 90



목 차

- 4.1 리눅스 시스템 기초
 - 4.2 구글 코랩과 캐글의 연동
 - 4.3 구글 코랩과 타이타닉 데이터
 - 4.4 파이썬 코드로 타이타닉 데이터 분석하기
 - 4.5 데이터 분석 실습: 코로나19 확진자 추이 데이터
- 



데이터 분석에 사용할 라이브러리

pandas

- 데이터를 읽고 분석하는 함수 제공하는 라이브러리

matplotlib

- 그래프 관련 함수 제공하는 라이브러리

- pandas와 matplotlib 를 사용해, 파이썬 코드로 데이터를 분석할 수 있음
- pandas, matplotlib가 설치되지 않은 경우 설치 필요 (코랩에는 이미 설치되어 있음)

Getting Started Prediction Competition

Titanic: Machine Learning from Disaster

Start here! Predict survival on the Titanic and get familiar with ML basics

Kaggle · 20,809 teams · Ongoing

Overview Data Notebooks Discussion Leaderboard Rules Team My Submissions **Submit Predictions**

Data Description

Overview

The data has been split into two groups:

- training set (train.csv)
- test set (test.csv)

The training set should be used to build your machine learning models. For the training set, we provide the outcome (also known as the "ground truth") for each passenger. Your model will be based on "features" like passengers' gender and class. You can also use [feature engineering](#) to create new features.

The test set should be used to see how well your model performs on unseen data. For the test set, we do not provide the ground

```
>_ kaggle competitions download -c titanic
```




실습순서

1. 구글 드라이브의 Colab Notebook 폴더로 이동



```
cd '/content/gdrive/My Drive/Colab Notebooks/'
```

- 폴더 위치가 /로 시작하면 절대경로를 의미
- cd 명령에서 절대경로를 지정하면 현재 폴더와 관계없이 해당 폴더로 이동



실습순서

1. 구글 드라이브의 Colab Notebook 폴더로 이동
2. pandas 라이브러리의 read_csv 함수를 사용하여 csv 데이터 읽음



```
import pandas as pd
data_train = pd.read_csv('./titanic_data/train.csv')
print(data_train)
```

- csv 함수는 콤마(,)로 데이터가 나뉘어져 있음. 메모장 등에서 확인 가능
- read_csv([파일경로]) 함수는 지정된 csv 파일을 읽어 pandas의 DataFrame 형태로 반환함
- 데이터를 읽어 data_train 변수에 저장하였음
- DataFrame은 numpy의 배열과 유사하지만, 2차원 Table 형태에 최적화되어 있음
- print() 함수를 사용해 DataFrame의 형태를 살펴볼 수 있음

	PassengerId	Survived	Pclass	...	Fare	Cabin	Embarked
0	1	0	3	...	7.2500	NaN	S
1	2	1	1	...	71.2833	C85	C
2	3	1	3	...	7.9250	NaN	S
3	4	1	1	...	53.1000	C123	S
4	5	0	3	...	8.0500	NaN	S
...	...	...	...	...	...	...	...
886	887	0	2	...	13.0000	NaN	S
887	888	1	1	...	30.0000	B42	S
888	889	0	3	...	23.4500	NaN	S
889	890	1	1	...	30.0000	C148	C
890	891	0	3	...	7.7500	NaN	Q

[891 rows x 12 columns]




실습순서

1. 구글 드라이브의 Colab Notebook 폴더로 이동
2. pandas 라이브러리의 read_csv 함수를 사용하여 csv 데이터 읽음
3. matplotlib 라이브러리의 pyplot 모듈을 사용하여 좌석등급별 인원비교



```
import matplotlib.pyplot as plt  
plt.hist(data_train['Pclass'])
```

- 그래프를 그리는 데에는 matplotlib의 pyplot 모듈이 많이 사용됨
- hist(배열) 함수는 데이터분포를 히스토그램으로 보여주는 함수
- DataFrame 변수['열 이름'] 은 DataFrame에서 특정 열만 선택(추출)할 때 사용
- 3등급 객실의 탑승자가 1,2등급 객실의 탑승자 합보다 많음을 알 수 있음






실습순서

1. 구글 드라이브의 Colab Notebook 폴더로 이동
2. pandas 라이브러리의 read_csv 함수를 사용하여 csv 데이터 읽음
3. matplotlib 라이브러리의 pyplot 모듈을 사용하여 좌석등급별 인원비교
4. matplotlib 라이브러리의 pyplot 모듈을 사용하여 좌석등급별 생존비교



```
data_survived = data_train[data_train.Survived==1]
plt.hist([data_train['Pclass'], data_survived['Pclass']])
plt.legend(['Total','Survived'])
plt.xlabel('Pclass')
plt.ylabel('Number of People')
```

- data_train의 전체 데이터 중, 생존자의 데이터만을 별도로 저장
`data_survived = data_train[data_train.Survived==1]`
- data_train.Survived==1은 해당 값이 1인 데이터의 경우에는 True, 0인 경우에는 False를 가지는 Boolean형 시리즈(Pandas 에서 사용하는 1차원 배열)로 나타남
- hist 함수에 두 개의 데이터를 파라미터로 넘겨주어, 각각에 대한 히스토그램을 그릴 수 있음
- legend 함수는 범례를 표시
- xlabel, ylabel은 각각 x,y축의 제목을 표시하는 함수임





실습순서

1. 구글 드라이브의 Colab Notebook 폴더로 이동
2. pandas 라이브러리의 read_csv 함수를 사용하여 csv 데이터 읽음
3. matplotlib 라이브러리의 pyplot 모듈을 사용하여 좌석등급별 인원비교
4. matplotlib 라이브러리의 pyplot 모듈을 사용하여 좌석등급별 생존비교
5. 남성이면서 생존했는지를 판단하는 boolean 변수 생성



`(data_train.Survived==1) & (data_train.Sex=='male')`

```
0      False
1      False
2      False
3      False
4      False
...
886     False
887     False
888     False
889      True
890     False
Length: 891, dtype: bool
```

- & 기호를 사용해 두 가지의 조건을 동시에 만족하는 행을 찾을 수 있음
- | 기호는 두 가지의 조건 중 하나 이상을 만족하는 행을 찾는 데 사용됨



실습순서

1. 구글 드라이브의 Colab Notebook 폴더로 이동
2. pandas 라이브러리의 read_csv함수를 사용하여 csv 데이터 읽음
3. matplotlib 라이브러리의 pyplot모듈을 사용하여 좌석등급별 인원비교
4. matplotlib 라이브러리의 pyplot모듈을 사용하여 좌석등급별 생존비교
5. 남성이면서 생존했는지를 판단하는 boolean 변수 생성
6. 남성 생존자 및 여성 생존자 데이터를 추출




```
survived_m = data_train[(data_train.Survived==1) | (data_train.Sex=='male')]
survived_f = data_train[(data_train.Survived==1) | (data_train.Sex=='female')]
```

- 생존자 남성과 생존자 여성을 각각 별도의 변수에 저장



실습순서

1. 구글 드라이브의 Colab Notebook 폴더로 이동
2. pandas 라이브러리의 read_csv 함수를 사용하여 csv 데이터 읽음
3. matplotlib 라이브러리의 pyplot 모듈을 사용하여 좌석등급별 인원비교
4. matplotlib 라이브러리의 pyplot 모듈을 사용하여 좌석등급별 생존비교
5. 남성이면서 생존했는지를 판단하는 boolean 변수 생성
6. 남성 생존자 및 여성 생존자 데이터를 추출
7. 남성 생존자, 여성 생존자 수를 히스토그램으로 표시



```
plt.hist([data_train['Pclass'], survived_m['Pclass'], survived_f['Pclass']], bins=3)
plt.legend(['Total', 'Survived_m', 'Survived_f'])
plt.xlabel('Pclass')
plt.ylabel('Number of People')
plt.xticks([1, 2, 3])
```

- 전체 탑승자, 생존자 남성, 생존자 여성에 대한 히스토그램을 표시
- xticks 함수는 x축의 눈금을 지정함



연습문제

1. or 기호를 사용해서 여성, 1등석 중 하나 이상의 조건을 만족하는 승객의 데이터를 모아서 히스토그램으로 그려 보라.
성별이 여성인 경우는 (data_train.Sex== 'female'),
객실 등급이 1등석인 경우는 (data_train.Pclass==1) 로 적을 수 있다.
2. 이와 같은 방식으로 다른 항목들도 분석해 볼 수 있다.
함께 탑승한 가족의 수, 나이와 생존여부의 관계를 분석해 보라.
 - 히스토그램 분석을 위한 파이썬 코드를 작성하고, 히스토그램을 그려라.
 - 히스토그램을 통해 새롭게 얻은 정보를 기술하라.



분석결과를 바탕으로 하는 정답 예측
&제출

1. 테스트 데이터에 대한 정답 예측

- 테스트 데이터 읽기



```
data_test = pd.read_csv('./titanic_data/test.csv')
```

- 정답데이터를 나타내는 변수 생성과 설정



```
answer = np.zeros( (len(data_test), 2) )  
answer[:,0] = data_test['PassengerId']
```

- 정답 예측



```
# 1등석 승객에 대한 답은 1(생존)로 설정한다.  
answer[(data_test.Pclass==1),1] = 1;  
# 2등석 승객이면서 여성인 경우 1(생존)로 설정한다.  
answer[ (data_test.Pclass==2) and (data_test.Sex=='female'),1] = 1
```

- len(배열 이름) 은 배열의 길이를 알려주는 함수
- [테스트 데이터의 길이]x2 크기의 numpy 배열 생성
- answer의 첫 번째 열은 PassengerID로 지정

- data_test.Pclass==1은 1등석인 경우 True, 그렇지 않은 경우 False인 Boolean 배열(시리즈)
- 생존을 예측하는 경우, answer의 두 번째 열 정보 변경



분석결과를 바탕으로 하는 정답 예측 & 제출

1. 테스트 데이터에 대한 정답 예측
2. 제출

- numpy 배열을 DataFrame으로 변경



```
df_answer = pd.DataFrame(answer)
df_answer.columns = ['PassengerID', 'Survived']
df_answer = df_answer.astype('int32')
df_answer.to_csv('./titanic_data/test_predict.csv', index = False)
```

- DataFrame(numpy배열) 명령으로 numpy배열을 DataFrame으로 변경 가능
- DataFrame의 column이름 설정
- 실수형으로 저장된 데이터를 정수형으로 변경
- csv 파일로 저장



```
!kaggle competitions submit -c titanic -f './titanic_data/test_predict.csv' -m "Message"
```

- 파이썬 코드를 사용하여 코랩에서 캐글에 직접 제출
- csv파일을 다운로드 한 후, 웹페이지상에서 제출해도 무방



목 차

- 4.1 리눅스 시스템 기초
- 4.2 구글 코랩과 캐글의 연동
- 4.3 구글 코랩과 타이타닉 데이터
- 4.4 파이썬 코드로 타이타닉 데이터 분석하기
- 4.5 데이터 분석 실습: 코로나19 확진자 추이 데이터




대한민국의 누적 확진자 현황

1. 데이터셋 다운로드



(a)



(b)

[그림 4-8] 코로나19 확진자 추이 ① 데이터셋 페이지와 ② 파일 리스트

- 코로나 바이러스 2019 데이터셋 페이지에 접속하여 데이터 다운로드
 - <https://www.kaggle.com/sudalairajkumar/novel-corona-virus-2019-dataset>
 - ~~confirmed.csv, ~~ deaths.csv, ~~recovered.csv 의 3개 파일 다운로드
 - ~~US.csv 파일은 미국 데이터를 주별로 상세히 정리해 놓은 자료임



대한민국의 누적 확진자 현황

1. 데이터셋 다운로드
2. 코랩과 구글 드라이브 연동 & 데이터 업로드




```
from google.colab import drive
```

```
#구글 드라이브 연동  
drive.mount('/content/gdrive')
```

```
#폴더 생성  
!mkdir '/content/gdrive/MyDrive/Colab Notebooks/covid19'
```

- 코드를 사용하여 구글 드라이브를 연동하고, 폴더 생성
- 캐글의 파일 업로드 메뉴를 사용하여 다운로드 받은 데이터를 업로드



[그림 4-9] 파일 업로드 메뉴



대한민국의 누적 확진자 현황

1. 데이터셋 다운로드
2. 코랩과 구글 드라이브 연동 & 데이터 업로드
3. 데이터를 읽고 변수에 저장



```
import pandas as pd
confirmed_df = pd.read_csv('time_series_covid_19_confirmed.csv')
deaths_df = pd.read_csv('time_series_covid_19_deaths.csv')
recovered_df = pd.read_csv('time_series_covid_19_recovered.csv')
```

- 데이터 종류
 - confirmed_df: 확진자 데이터
 - deaths_df: 사망자 데이터
 - recovered_df: 회복자 데이터
- 데이터 내용 확인

confirmed_df																		
	Province/State	Country/Region	Lat	Long	1/22/20	1/23/20	1/24/20	1/25/20	1/26/20	1/27/20	1/28/20	1/29/20	1/30/20	1/31/20	2/1/20	2/2/20	2/3/20	
0	NaN	Afghanistan	33.939110	67.709953	0	0	0	0	0	0	0	0	0	0	0	0	0	0
1	NaN	Albania	41.153300	20.168300	0	0	0	0	0	0	0	0	0	0	0	0	0	0
2	NaN	Algeria	28.033900	1.659600	0	0	0	0	0	0	0	0	0	0	0	0	0	0
3	NaN	Andorra	42.506300	1.521800	0	0	0	0	0	0	0	0	0	0	0	0	0	0
4	NaN	Angola	-11.202700	17.873900	0	0	0	0	0	0	0	0	0	0	0	0	0	0
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
269	NaN	Vietnam	14.058324	108.277199	0	2	2	2	2	2	2	2	2	2	6	6	8	
270	NaN	West Bank and Gaza	31.952200	35.233200	0	0	0	0	0	0	0	0	0	0	0	0	0	0
271	NaN	Yemen	15.552727	48.516388	0	0	0	0	0	0	0	0	0	0	0	0	0	0
272	NaN	Zambia	-13.133897	27.849332	0	0	0	0	0	0	0	0	0	0	0	0	0	0
273	NaN	Zimbabwe	-19.015438	29.154857	0	0	0	0	0	0	0	0	0	0	0	0	0	0



대한민국의 누적 확진자 현황

1. 데이터셋 다운로드
2. 코랩과 구글 드라이브 연동 & 데이터 업로드
3. 데이터를 읽고 변수에 저장
4. 특정국가의 정보만을 추출



```
idx_korea = (confirmed_df['Country/Region'] == 'Korea, South')
confirmed_korea_df = confirmed_df[idx_korea]
```



```
confirmed_korea_df
```

- 국가정보가 'Korea, South'인 데이터의 index 정보 (True/False)를 획득하고
- 해당 국가의 데이터만을 추출

	Province/State	Country/Region	Lat	Long	1/22/20	1/23/20	1/24/20	1/25/20	1/26/20	1/27/20	1/28/20	1/29/20	1/30/20
158	NaN	Korea, South	35.907757	127.766922	1	1	2	2	3	4	4	4	4

[그림 4-11] 국내 확진자 추이



대한민국의 누적 확진자 현황

1. 데이터셋 다운로드
2. 코랩과 구글 드라이브 연동 & 데이터 업로드
3. 데이터를 읽고 변수에 저장
4. 특정국가의 정보만을 추출
5. 추출된 정보를 그래프로 그려 확인

- 추출된 데이터를 numpy 배열로 변환 (array 함수)
- 0-3번 열 (주, 국가, 위도, 경도 정보) 삭제 (슬라이싱)
- xticks 함수를 사용하여 눈금 정보를 조정
→ 데이터가 매우 많으므로, 일부 눈금만 나올 수 있도록 조정
 - range의 step을 100으로 하여 특정 위치의 label만을 표시




```
import matplotlib.pyplot as plt
import numpy as np
```

```
confirmed_korea_np = np.array(confirmed_korea_df) #numpy배열로 변환
confirmed_korea_np = confirmed_korea_np[:,4:] #0-3번 열 삭제
```



```
plt.plot(confirmed_korea_np[0,:])
label_x = confirmed_korea_df.columns.values[4:]
sel_ids = range(0,len(label_x),100)
plt.xticks(sel_ids,labels=label_x[sel_ids])
```




[그림 4-12] 대한민국의 누적 확진자 그래프

책에 잘못된 숫자가 기입되어 있습니다.
p.225



국내 누적 확진자/사망자/회복자 현황

- 누적 사망자, 누적 회복자에 대해 같은 방식으로 데이터 추출
- 하나의 그래프에 세 가지 데이터를 모두 plot
- 눈금정보, 범례 등 조정



[그림 4-13] 국내 코로나19 바이러스 확진자, 사망자, 회복자 수 추이



```
# 누적 사망자 수 가져오기
idx_korea = (deaths_df['Country/Region']=='Korea, South')
deaths_korea_df = deaths_df[idx_korea] #국내 데이터 추출
deaths_korea_np = np.array(deaths_korea_df) #numpy배열로 변환
deaths_korea_np = deaths_korea_np[:,4:] #0-3번 열 삭제
```

```
# 누적 회복자 수 가져오기
idx_korea = (recovered_df['Country/Region']=='Korea, South')
recovered_korea_df = recovered_df[idx_korea] #국내 데이터 추출
recovered_korea_np = np.array(recovered_korea_df) #numpy배열로 변환
recovered_korea_np = recovered_korea_np[:,4:] #0-3번 열 삭제
```



```
plt.figure(figsize=(10,7))
```

```
#확진자/사망자/회복자 그래프
plt.plot(confirmed_korea_np[0,:])
plt.plot(deaths_korea_np[0,:])
plt.plot(recovered_korea_np[0,:])
```

```
#눈금정보 조정 & 범례 설정
label_x = confirmed_korea_df.columns.values[4:]
sel_ids = range(0,len(label_x),100) # 눈금을 표시할 위치 선택
plt.xticks(sel_ids,labels=label_x[sel_ids], fontsize=15)
plt.yticks(fontsize=15)
plt.legend(['Confirmed','Death','Recovered'], fontsize=15)
```



국내 사망자/확진자 비율

- 사망자/대비 확진자 비율 계산
- / 기호를 사용하여 numpy 배열의 각 항목별(element-wise)계산 가능
- argmax 함수를 사용하여 비율이 가장 높은 일자 확인 가능




```
#사망자/확진자 비율 계산
recovered2confirmed_ratio = deaths_korea_np[0,:]/ confirmed_korea_np[0,]
```

```
# 확진자 그래프 그리기
plt.figure(figsize=(10,7))
plt.plot(recovered2confirmed_ratio)
```

```
#눈금 표시
label_x = confirmed_korea_df.columns.values[4:]
sel_ids = range(0,len(label_x),100)
plt.xticks(sel_ids,labels=label_x[sel_ids], fontsize=15)
plt.yticks(fontsize=15)
```



```
idx_max = np.argmax(recovered2confirmed_ratio)
print(f'사망자/확진자 비율이 최대인 일자: {label_x[idx_max]} 이며')
print(f'해당 일자의 값은 {recovered2confirmed_ratio[idx_max]:.3f}입니다')
```



[그림 4-14] 국내의 확진자 대비 사망자 비율 추이

47

감사합니다

THANK YOU